

Acceso al portal protegido por Cloudflare


Propósito

El portal público de jurisprudencia puede responder a una consulta HTTP con una página de verificación de Cloudflare en lugar del HTML del buscador. Cuando eso ocurre, el MVP no puede tratar la respuesta como un resultado de jurisprudencia: la identifica como CHALLENGE_REQUIRED y cambia al acceso mediante un navegador Chromium normal.

Este documento describe el procedimiento técnico incorporado en el MCP y la aplicación. No es un bypass de Cloudflare ni intenta evadir sus controles: la verificación se completa en una sesión de navegador autorizada y el MCP solo reutiliza esa sesión para leer el resultado público.

Diseño del flujo

Consulta one-shot de la web



El MCP usa tres herramientas de acceso al portal:

- `search_jurisprudencia`: busca y devuelve metadatos, IDs y URLs de PDF.
- `get_jurisprudencia_detail`: recupera el detalle HTML de un fallo.
- `get_jurisprudencia_pdf_text`: captura el PDF público desde la red del navegador y extrae su texto localmente con `pdftotext`.

La herramienta `diagnose_jurisprudencia_access` informa si el acceso HTTP está recibiendo un desafío y si el endpoint CDP está disponible.

Procedimiento recomendado: Chrome del host + CDP

Este es el camino más estable para un desafío que requiere una sesión gráfica. El navegador se inicia manualmente con un perfil separado del perfil personal y con el puerto CDP escuchando únicamente en 127.0.0.1.

1. Preparar configuración

```
cp .env.example .env
```

En .env:

```
JURIS_ACCESS_MODE=browser  
JURIS_CDP_URL=http://127.0.0.1:9222  
JURIS_CHALLENGE_TIMEOUT_MS=60000
```

2. Iniciar Chrome manualmente

Desde una sesión gráfica del host:

```
DISPLAY=:0 ./scripts/start-host-chrome.sh
```

El script:

1. localiza google-chrome o chromium;
2. usa /tmp/mvp-jurisprudencia-chrome-profile por defecto, sin mezclar cookies con el perfil personal;
3. inicia el navegador sin reinicio automático;
4. habilita CDP en 127.0.0.1:9222;
5. deja una pestaña about:blank disponible para el MCP.

Abrir manualmente el buscador en esa ventana si aparece la verificación y completarla de forma interactiva. Una vez que el portal muestra su contenido normal, la aplicación puede reutilizar la misma pestaña y sus cookies de sesión.

3. Iniciar la aplicación

```
docker compose up -d --build
```

El Compose usa network_mode: host, por lo que el contenedor puede alcanzar 127.0.0.1:9222 del mismo host. El servicio tiene restart: "no"; tanto Chrome como la aplicación deben arrancarse manualmente.

4. Comprobar el acceso

```
curl http://localhost:3000/api/diagnose
```

El estado esperado cuando Chrome está disponible es:

```
{  
  "cdpConfigured": true,  
  "cdpReachable": true,  
  "recommendedAccessMode": "cdp"  
}
```

Después se puede ejecutar una consulta desde la interfaz web o mediante POST /api/query.

Alternativa contenida: Chromium + Xvfb

Si no se configura JURIS_CDP_URL, el MCP puede iniciar Chromium dentro del contenedor. Cuando no existe DISPLAY y JURIS_USE_XVFB=1, crea una pantalla virtual con Xvfb. El modo se selecciona así:

```
JURIS_ACCESS_MODE=auto  
JURIS_HEADLESS=0  
JURIS_USE_XVFB=1
```

JURIS_HEADLESS=0 es intencional: una sesión no-headless conserva mejor el comportamiento esperado por sitios que requieren JavaScript, cookies y una sesión de navegador completa. Este camino puede no superar todos los desafíos; si Cloudflare requiere una interacción adicional, se recomienda el navegador gráfico del host.

El contenedor instala chromium-sandbox y el Compose desactiva únicamente el seccomp restrictivo que impedía crear los namespaces requeridos por Chromium. No se usa --no-sandbox.

Qué hace el MCP cuando navega

1. directFetch intenta HTTP directo en modo auto.
2. La respuesta se inspecciona buscando la cabecera cf-mitigated y señales como Just a moment, Security Check Required o Verificando la conexión.
3. Si hay desafío, el MCP inicia o conecta Chromium.
4. La sesión navega a la URL original y espera hasta JURIS_CHALLENGE_TIMEOUT_MS.
5. Solo continúa cuando el documento está completo y ya no muestra el desafío.
6. Para los PDFs, escucha la respuesta de red con Fetch/Network y obtiene el cuerpo binario, sin depender de una descarga directa que perdería las cookies de la sesión.

El MCP no resuelve CAPTCHAs, no modifica tokens de Cloudflare, no falsifica encabezados de navegador y no intenta saltar controles de acceso. Si la verificación no termina, devuelve el estado visible de la página para facilitar el diagnóstico.

Diagnóstico de errores habituales

ECONNREFUSED 127.0.0.1:9222

Chrome CDP no está escuchando o el contenedor no fue iniciado con la misma configuración. Comprobar:

```
curl http://127.0.0.1:9222/json/version
```

Si falla, ejecutar nuevamente `DISPLAY=:0 ./scripts/start-host-chrome.sh` y confirmar que `/tmp/mvp-jurisprudencia-chrome.log` no informa un error de Chrome.

No usable sandbox

Es un problema de ejecución de Chromium dentro del contenedor. La imagen ya instala `chromium-sandbox` y el Compose incluye `security_opt: seccomp=unconfined`. Reconstruir la imagen con:

```
docker compose up -d --build
```

No agregar `--no-sandbox` salvo que se evalúe conscientemente el impacto de seguridad en un entorno descartable.

Cloudflare no completó el desafío dentro del tiempo permitido

La sesión no llegó a contenido normal dentro del plazo. Revisar el estado de la pestaña Chrome, completar cualquier interacción pendiente y aumentar localmente el valor si la red necesita más tiempo:

```
JURIS_CHALLENGE_TIMEOUT_MS=120000
```

También puede ocurrir que la política del portal no permita ese origen, IP o automatización. En tal caso el MCP debe reportar el bloqueo; no hay garantía de que Xvfb o un navegador externo resuelvan todos los desafíos.

Consideraciones de seguridad y operación

- El perfil temporal puede contener cookies de la sesión; no debe publicarse ni incorporarse al repositorio.
- CDP no debe exponerse a 0.0.0.0 ni publicarse mediante un proxy.
- `.env` puede contener configuración local o credenciales de proveedores de IA; permanece fuera del repositorio.
- Las consultas y los documentos recuperados se procesan localmente antes de enviarse al proveedor de síntesis configurado.
- El contenido jurídico debe verificarse contra la fuente oficial y no constituye asesoramiento legal.